

INTRODUCTION TO COMPUTER VISION

PROJECT DOCUMENTATION



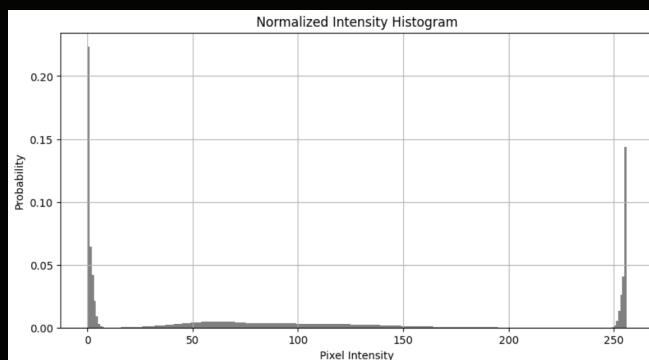
Ferdowsi University of Mashhad
Department of Computer Engineering

SPRING 2025

نام و نام خانوادگی	شماره دانشجویی
امیرحسین افشار	۴۰۱۲۶۲۱۹۶

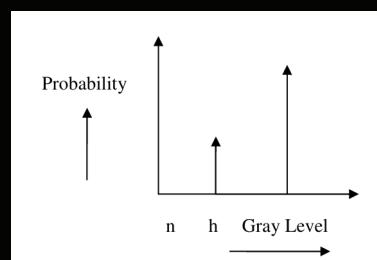
(۱) سوال اول: معماه داوینچی

در ابتدا برای حل پازل، عملیات denoising *processed_img_part_1.jpg* را برای تصویر *denoising* انجام شد. بدین منظور، از هیستوگرام تصویر بهره گرفته شده است [۱]؛ هیستوگرام تصویر با سطوح خاکستری، بر اساس نرمال کردن میزان پیکسل های با شدت بین ۰ تا ۲۵۵ ساخته می شود تا شکل function ۱ این شکل است:



شکل ۱: پلات هیستوگرام تصویر نویزی شماره ۱

این شکل، بیان می کند که تعداد پیکسل ها با مقدار نزدیک به صفر و مقدار نزدیک به ۲۵۵ بسیار زیاد است. همچنین هیستوگرام احتمال قابل انتظار برای تصاویر نویزی با نوع نویز نمک فلفل به شکل زیر است:



شکل ۲: هیستوگرام قابل انتظار برای تصاویر نویزی نمک و فلفل

[۱] Asoke Nath: Image Denoising Algorithms: A Comparative Study of Different Filtration Approaches Used in Image Restoration

با مقایسه شکل ۱ و ۲ می توان نتیجه گرفت که نویز تصویر شماره ۱ از نوع نمک و فلفل می باشد. بنابراین، برای کردن تصویر، بهترین گزینه، استفاده از فیلتر median می باشد. شایان ذکر است که در عملیات denoise کردن تصویر برای اطمینان بیشتر از نوع نویز، از انواع فیلترها استفاده شد که به شرح زیر هستند:

Category	Filter Name	Function
Smoothing Filters	Box Filter	denoise_box_filter
	Gaussian Filter	denoise_gaussian_filter
Statistical Filters	Median Filter	denoise_median_filter
	Max Filter	denoise_max_filter
	Min Filter	denoise_min_filter
Advanced Filters	Bilateral Filter	denoise_bilateral_filter
	Non-Local Means	denoise_nl_means
	Wavelet Filter	denoise_wavelet_filter
	Total Variation Filter	denoise_total_variation

جدول ۱: انواع فیلتر ها و توابع denoising به کار گرفته شده

همانطور که از شکل ۱ انتظار می رفت، بهترین عملکرد خروجی با استفاده از فیلتر میانه یا همان median بدست می آید. در نهایت، برای نهایی کردن بهترین خروجی با استفاده از فیلتر میانه، دو روش پیگیری شد:

۱. استفاده از چند مرحله فیلتر median با ابعاد یکسان

۲. استفاده از یک فیلتر median با کرنل بزرگتر

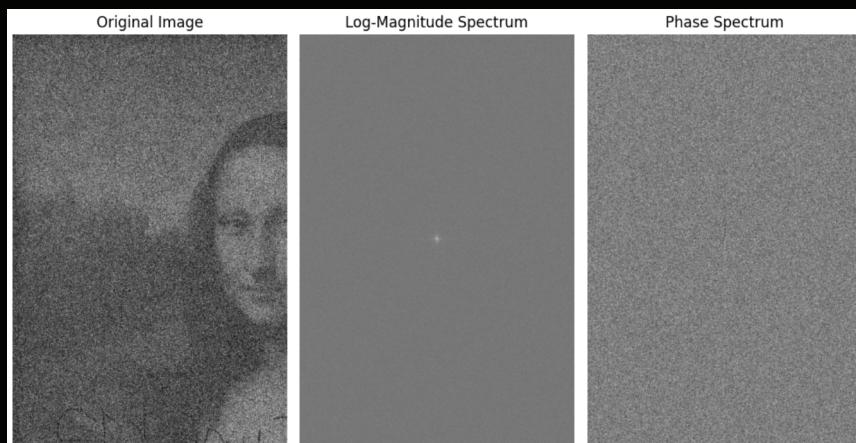
روش اول، به طور کلی برای حفظ جزئیات تصویر مناسب تر است؛ زیرا هرگونه کرنل بزرگ با ریسک از دست دادن جزئیات همراه است. از طرفی، ممکن است که همگرا شدن تصویر پس از اعمال چند بار فیلتر میانه، به کندی پیش روی و حتی برخی نویز ها در تصویر باقی بمانند که این مشکل، در روش دوم وجود ندارد.

در نهایت، با توجه به مسئله که تنها نیاز است یک متن از تصویر استخراج شود (و حفظ سایر جزئیات دارای اهمیت کمتری است)، از روش دوم استفاده شد.



شکل ۳: شکل نهایی تصویر denoise شده

همچنین شایان ذکر است که برای درک بهتر نویز، از حوزه‌ی فرکانس نیز کمک گرفته شد^[1] که بتوان نوع نویز را حدس زد و در نهایت با استفاده از فیلترهای notch و band-pass یا band-reject از نویز تصویر کاست. شکل سوم بیانگر این موضوع است.



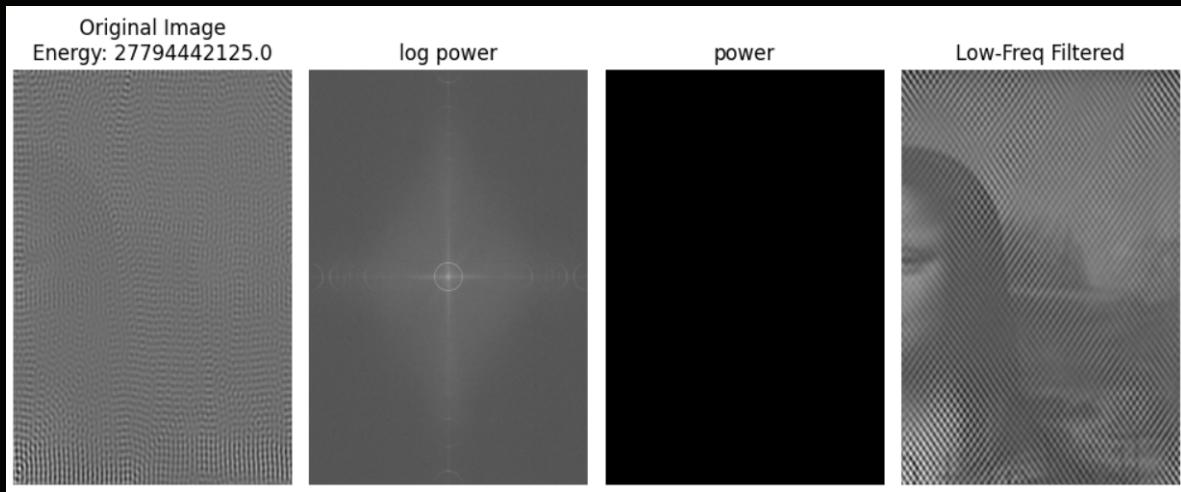
شکل ۴: تصویر شماره ۱ در حوزه فرکانس

با توجه به magnitude تصویر در حوزه فرکانس، نمی‌توان نویز خاصی را قائل شد که نهایتاً، همان فیلتر میانه که از هیستوگرام تصویر درک شده بود، استفاده شد.

^[1] Digital Image Processing By Gonzalez 2nd Edition 2002, chapter 4.2

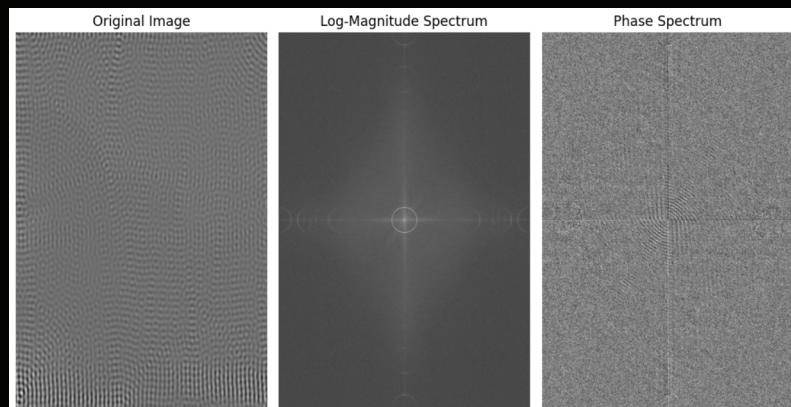
۰ بخش دوم

برای این بخش باید تصویر *processed_img_part_2.jpg* اصلاح می شد. بدین منظور و در ابتدا برای تشخیص نویز، از انرژی و *magnitude* تصویر استفاده شد؛ زیرا تصویر کاملا پوشیده از نویز بود و پیش بینی نوع نویز را سخت می کرد. همچنین برای درک بهتر کلیت تصویر، با حذف فرکانس های بالا، یک تخمین از کلیت تصویر به دست آمده است. برای این منظور، پلات زیر رسم شده است:



شکل ۵: پیش بینی نوع نویز در تصویر دوم

با دقت کردن به لگاریتم *power* در پلات (شکل شماره ۵) متوجه یک حلقه می شویم که با الگوی سینوسی نویز در تصویر در حوزه مکان تطابق دارد. برای درک بهتر این نویز، به طور مستقل برای تصویر در حوزه فرکانس *magnitude* و *phase* رسم شده است که به شکل زیر است:

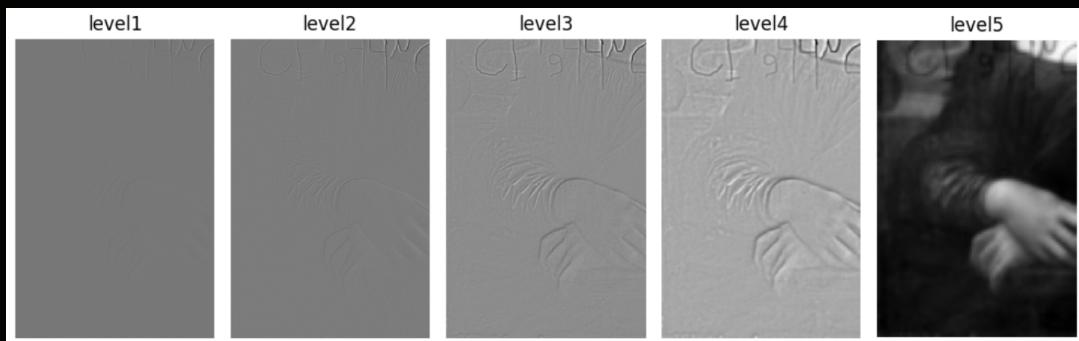


شکل ۶: تصویر دوم در حوزه فرکانس

که ایده اولیه را تایید می کند. بدین منظور، تنها و به سادگی با ساختن یک فیلتر *band-reject* در حوزه فرکانس، این مشکل حل شده و تصویر نهایی ساخته می شود.

۰ بخش سوم

برای بخش سوم از پازل، باید تصویر اصلی را از ۵ زیر تصویر reconstruct می کردیم. بدین منظور، تصاویر در ابتدا و در کنار یکدیگر plot شده اند:



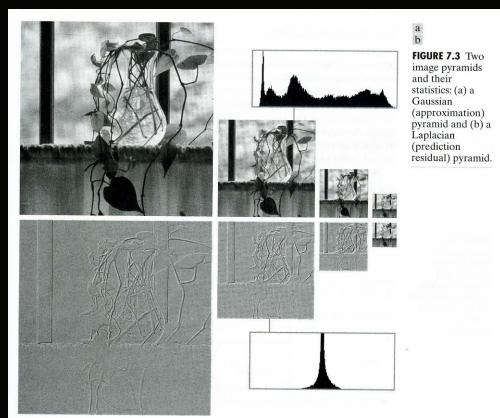
شکل ۷: زیرتصاویر بخش سوم پازل

همچنین ابعاد هر کدام از تصاویر در جدول زیر بیان شده است:

Image File	Width (px)	Height (px)
processed_img_part_3_Level_0.jpg	1796	1201
processed_img_part_3_Level_1.jpg	898	601
processed_img_part_3_Level_2.jpg	449	301
processed_img_part_3_Level_3.jpg	225	151
processed_img_part_3_Level_4.jpg	113	76

جدول ۲: ابعاد زیر تصاویر در بخش سوم پازل

با توجه به جدول شماره ۲ که بیانگر ابعاد پازل است، میتوان متوجه شد که در هر مرحله با تقریب هم طول و هم عرض تصویر نصف می شود. این موضوع، وجود نوعی pyramid را در ذهن تداعی می کند^[۱]. این موضوع، در زیربخش سوم فصل هفتم کتاب گونزالس^[۲] به این شکل آمده است:

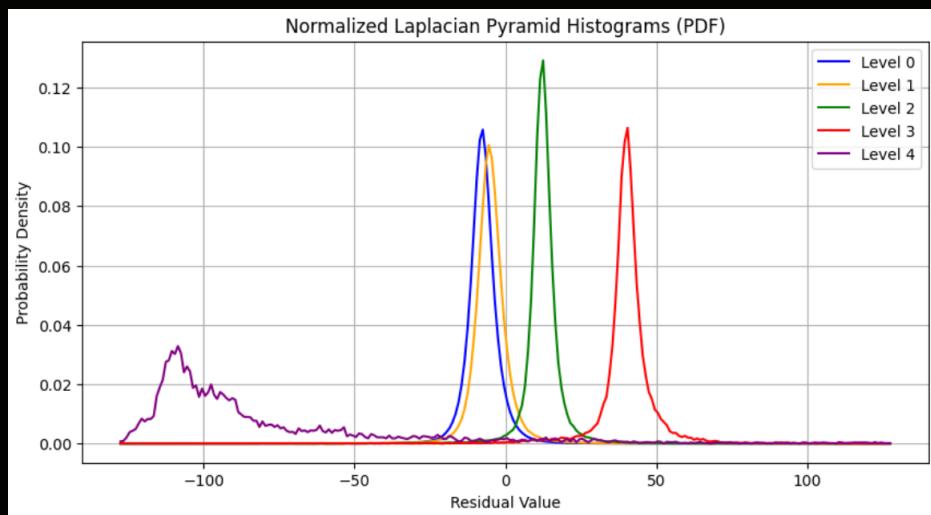


شکل ۸: انواع pyramid ها: کتاب گونزالس، زیربخش سوم فصل هفتم

[۱] medium: A Beginners Guide to Computer Vision (Part 4)- Pyramid

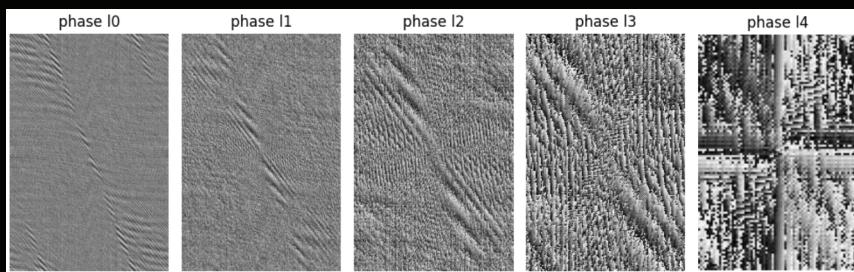
[۲] Digital Image Processing By Gonzalez 2nd Edition 2002, chapter 7.3

برای درک بهتر هرم، هیستوگرام احتمال برای هر کدام از زیر تصاویر رسم شده است:



شکل ۹: هیستوگرام در هرم

نمودار هیستوگرام نرمال شده هرم، توزیع آماری مقدارهای باقیمانده در هر سطح از هرم را نمایش می‌دهد. در فرآیند ساخت هرم، هر تصویر در یک سطح با نسخه‌ی بزرگ نمایی شده‌ی تصویر سطح بعدی کم می‌شود، و نتیجه این اختلاف، تصویر باقیمانده‌ای است که تنها حاوی اطلاعات لبه‌ها، جزئیات کوچک است. برای نمایش بهتر این اطلاعات، از یک آفست استفاده شده و همچنین نرمال سازی انجام شده است. در تایید این موضوع، از تبدیل به حوزه فوریه و نمایش فاز هر کدام از زیر تصاویر نیز استفاده شده است:



شکل ۱۰: هیستوگرام در هرم

همانطور که مشخص است، لبه‌های کوچک در سطوح بالا، دارای فاز یکنواخت تری هستند و هرچه به لایه‌های پایین‌تر می‌رویم، این یکنواختی کمتر می‌شود و تغییرات فرکانس وضوح می‌یابند. با دقیقت به این هیستوگرام، (و همچنین زیرتصاویر ارائه شده در شکل پنجم) میتوان نتیجه گرفت که هرم از نوع لاپلاسی است؛ هر مرحله از *downsample* شدن تصویر و محاسبه اختلاف با لایه قبلی محاسبه می‌شود که برای ساختن تصویر اصلی، کافیست معکوس این کار را انجام دهیم.

برای درست کردن تصویر، در ابتدا تلاش شد که با طی کردن فرایند به شکل معکوس، تصویر اصلی ساخته شود، اما تصویر خروجی شامل کیفیت مناسب نبود. بدین منظور، از تابع `resize` از کتابخانه `cv2` استفاده شد که به صورت خطی تصویر را تغییر سایز می‌دهد. همچنین، برای بهبود نهایی، مقادیر `grayscale` به `uint8` تغییر یافته اند؛ به عبارتی، مقادیر قبلی سطوح خاکستری با این کار، به بازه (۰، ۲۵۵) گسترش یافتند که باعث بهبود کنترast شد. تصویر نهایی ساخته شده نیز در شکل ۹ آمده شده است:



شکل ۱۱: تصویر نهایی ساخته شده از زیرتصاویر

(۲) پروژه دوم: تصاویرنویزی/غیرنویزی

در این پروژه، هر دو روش یادگیری عمیق و بینایی ماشین کلاسیک پیاده سازی شده است. در ابتدا به تفصیل، روش یادگیری عمیق توضیح داده می شود:

(۳) یادگیری عمیق در پروژه دوم

در ابتداء، برای پیاده سازی سیستم تشخیص نویزها، این نیاز دیده می شد که دیتاست های در اختیار قرار گرفته، دیتاست های کوچکی هستند و برای روش های ml و یا dl مناسب نیستند. به گونه ای که حتی با augment کردن داده ها و پیاده سازی بر روی مدل های pre-trained و با tune fine آنها نیز، کفایت نمی کرد. بنابراین، با بررسی دیتاست های قرار داده شده کشاورزی که از نوع برگ درختان هستند، دیتاست های کاندیدا از وبسایت kaggle به شرح زیر هستند:

1. <https://www.kaggle.com/datasets/ichhadhari/leaf-images>
2. <https://www.kaggle.com/datasets/mdwaquarazam/agricultural-crops-image-classification/data>
3. <https://www.kaggle.com/datasets/alexo98/leaf-detection>

که طبق بررسی انجام شده، بهترین و مشابه ترین دیتاست، مربوط به دیتاست leaf-detection است. دقت شود که این موضوع که دیتاست ها باید برای استفاده این پروژه به شکل کاملی شخصی سازی شوند (به عنوان مثال، نویز به تصاویر اضافه شود) کاملاً واضح است و از ابتداء صرفاً به دنبال دیتاست هایی صرفاً با زمینه مرتبط بودم و سپس دیتاست ها را به شکل مناسبی برای استفاده از این پروژه شخصی سازی کردم. مجدداً تاکید می شود که دیتاست انتخاب شده، صرفاً انواع برگ های گوناگون بوده است و هیچ هدفی از نویز/دینویز کردن تصاویر در این دیتاست دنبال نشده است.

بررسی دیتاست آورده شده:

با توجه به این که این دیتاست، صرفاً شامل تصاویری از برگ های ۱۰ نوع درخت هندی هستند، بدون توجه به لیبل های آن برگ ها، و صرفاً با در نظر گرفتن همه آنها از یک نوع، (همگی را به شکل یکسان و «برگ» در نظر گرفتم) به آنها انواع گوناگونی از نویز ها پیاده سازی کردم. در ابتداء، نویزهای تکی، یعنی:

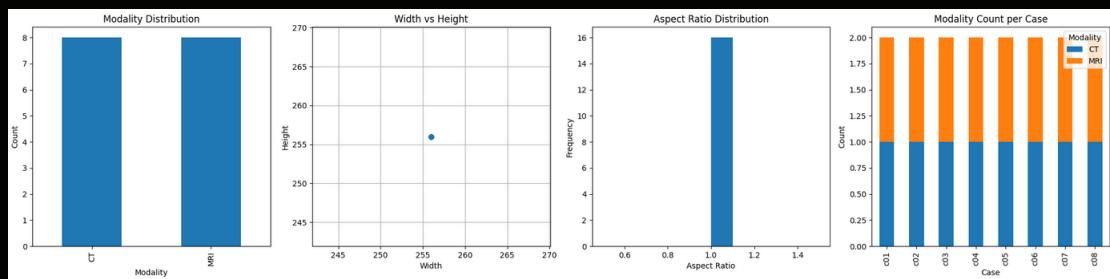
سپس انواع نویز های دو تایی (تمامی جایگشت ها لحاظ نشده است؛ به علت محدودیت پردازشی گوگل کولب به ۱۶ گیگ حافظه رم، بیش از این نوع نمیتوان جایگشت های مختلفی از نویز در نظر گرفت):

No.	Combinations	Noise Type
1	1	Gaussian
2	1	Salt & Pepper
3	1	Poisson
4	1	Speckle
5	1	Uniform
6	2	Gaussian + Salt & Pepper
7	2	Gaussian + Poisson
8	2	Gaussian + Speckle
9	2	Gaussian + Uniform
10	2	Salt & Pepper + Speckle
11	2	Salt & Pepper + Uniform
12	2	Poisson + Speckle
13	2	Poisson + Uniform
14	2	Speckle + Uniform
15	3	Gaussian + Salt & Pepper + Speckle
16	3	Gaussian + Poisson + Uniform
17	3	Salt & Pepper + Speckle + Uniform

جدول ۳: لیست انواع نویز های پیاده شده

(۴) پروژه سوم: ادغام تصاویر پزشکی

در این پروژه، ابتدا پیاده‌سازی با استفاده از روش‌های کلاسیک انجام شده و جزئیات مربوط به آن به‌طور کامل توضیح داده شده است. گام مشترک میان هر دو روش، پروفایل دیتا است. در ابتدا باید بر روی دیتاست عملیات پروفایل کردن دیتا انجام می‌شود که بررسی شود دیتاست تصاویر به شکل ct (که به شکل هستند که استخوان‌ها را به رنگ سفید نمایش می‌دهند) با تصاویر mri از نظر سایز، فرمت، طول و عرض تصویر و نسبت طول به عرض با یکدیگر تطابق دارند یا خیر. بدین منظور، نتیجه این پروفایل کردن در زیر قابل مشاهده است:

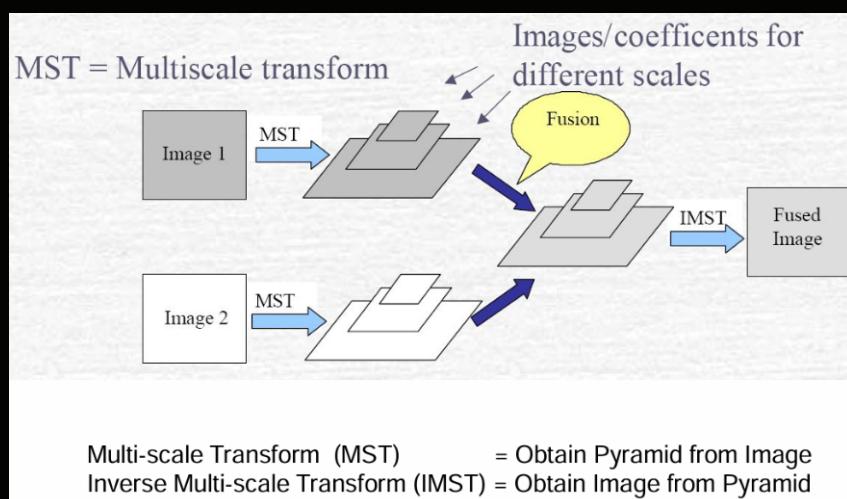


شکل ۱۲: نتیجه پروفایل دیتا

(شايان ذكر است که شاید گمان شود که برای اين دیتاست کوچک، نیازی به پروفایل کردن دقیق دیتا نبوده و صرفا یک مشاهده کوچک بر روی ۸ زوج عکس، کفايت میکند، اما روش ارائه شده برای هر تعداد جفت عکس ارائه شده قابل اجراست و مرحله ابتدایی الزامی هر پروژه ای محسوب میشود.)

راه حل با روش‌های بینایی کلاسیک

همانطور که در اسلاید های درسی داشتیم:



شکل ۱۳: نحوه ادغام دو نوع تصویر مختلف

باید pyramid هایی از هر دو نوع تصویر تهیه کنیم. در ابتدا ویژگی هایی که هر سطح از این pyramid ها شامل می شوند، به شکل زیر بیان می شود: این قانون در رابطه با هر دو نوع هرم گوسی

ویژگی‌های استخراج شده	فرکانس	اندازه تصویر	سطح
جزئیات ریز (لبه‌ها، بافت، نویز)	فرکانس بالا	اندازه کامل	سطح ۰
لبه‌های بزرگتر، اشکال	فرکانس متوسط	نصف اندازه	سطح ۱
نواحی صاف، روشنایی کلی	فرکانس پایین	یکچهارم اندازه	سطح ۲
ساختمار کلی، سایه‌روشن نرم	فرکانس بسیار پایین	بسیار کوچک	سطح N (بالا)

جدول ۴: ساختار سطوح در هرم تصویری

و لایپلاسی صدق می‌کند. (البته این دو هرم در نوع نمایششان با یکدیگر متفاوت هستند). در نهایت، مورد دیگری که باید بحث شود نحوه ادغام است که به این شکل چندین روش می‌توان به کار برد:

ویژگی‌های حفظ شده	عملکرد	Rule Fusion
اطلاعات متعادل	ترکیب برابر دو تصویر	(mean) Average
ویژگی‌های تیره	انتخاب مقدار کمینه هر پیکسل	Min
ویژگی‌های روشن	انتخاب مقدار بیشینه هر پیکسل	Max
لبه‌های قوی با فرکانس بالا	انتخاب پیکسلی با بیشترین قدر مطلق	Max-Abs
بافت، واریانس محلی	انتخاب پیکسل از تصویری با انرژی محلی بالاتر	Energy-Max
ساختمارهای برجسته	انتخاب پیکسل با لبه بیشتر	Saliency-Based
تأثیر قابل تنظیم	میانگین وزنی با وزن‌های دستی	(static) Weighted
ترکیب تطبیقی	وزن دهنی بر اساس انرژی	(adaptive) Weighted
ساختمارهای همبسته	تقسیم تصویر به مؤلفه‌های اصلی	PCA-Based

جدول ۵: قوانین مختلف ادغام تصویر و ویژگی‌های حفظ شده

پارامتر بعدی که باید بررسی شود، عمق این pyramid ها می‌باشد. به طور کلی، با توجه به اینجا:

- The Laplacian Pyramid as a Compact Image Code

اشاره شده است که برای تهیه هر هرمی، میتوان از الگوی زیر تبعیت کرد:

$$\text{max_levels} = \lfloor \log_2 (\min(H, W)) \rfloor$$

که با توجه به تصویر ورودی $256 * 256$ می‌توان هرم را به حداقل ۸ سطح تقسیم کرد. اکنون

راه حل با روش های یادگیری عمیق

به عنوان مطالعه‌ی تکمیلی، روش‌های مبتنی بر یادگیری عمیق را نیز بررسی کردم. به طور خاص مقاله‌ای که مطالعه کردم در اینجا قرار دارد:

- DM-FNet: Unified multimodal medical image fusion via diffusion process-trained encoder-decoder

روش‌های کلاسیکی که پیاده سازی شده است، صرفا شامل ساختارهای هرم بودند و در نهایت در پیشرفت‌ههای ترین مدل‌های خود، از ویولت استفاده می‌کردند که مشکل بزرگی داشتند: یا تصویر نهایی به شکل زیادی smooth می‌شود و یا جزئیات هر دو منبع ورودی را نمیتوان نگه داشت. این دو مورد انگیزه‌هایی بودند که برای حل این مسئله شبکه‌های عمیق سوق داده شده‌اند.

مرحله‌ی اول بر پایه‌ی DDPM طراحی شده است؛ مدلی که هدف آن، یادگیری معکوس‌سازی یک process noise forward به صورت مرحله‌به‌مرحله است. برخلاف کاربردهای معمول که در آن‌ها تصویر feature map به عنوان ابزاری برای استخراج های با کیفیت بالا و در مقیاس‌های مختلف از هر نوع تصویر MRI و CT به کار گرفته شده است.

در این چارچوب، برای هر مدل‌الیته یک model diffusion مبتنی بر UNet به صورت جداگانه آموزش داده شده است. هدف این مرحله بازسازی تصویر نیست، بلکه embedding کردن اطلاعات هر مدل‌الیته در یک فضای بازنمایی عمیق و سلسله‌مراتبی است که بتواند ساختارهای مهم تصویر را به خوبی نمایش دهد.

ویژگی‌هایی که در این مرحله استخراج می‌شوند، نقش نوعی سوپروایزر را برای نوع تصویر خود ایفا می‌کنند؛ به این معنا که مدل MRI در شناسایی ویژگی‌های مرتبه با tissue soft تخصص دارد، در حالی که مدل CT تمرکز بیشتری روی ساختارهای استخوانی دارد.

در مجموع، این مرحله مانند یک preprocessor هوشمند عمل می‌کند که به جای استفاده از feature extractor های سطحی و سنتی، از هایی encoder بهره می‌گیرد که با فرایند diffusion آموزش دیده‌اند و می‌توانند فیچر‌هایی دقیق ارائه دهند.

پس از استخراج feature deep ها از هر دو مدل‌الیته، مرحله‌ی دوم با نام

DFFM (Diffusion Feature Fusion Model)

وظیفه‌ی ادغام واقعی اطلاعات را بر عهده می‌گیرد. برخلاف روش‌های ساده‌ای مانند میانگین‌گیری یا روی هم قرار دادن مستقیم ویژگی‌ها، در این‌جا فرایند fusion با استفاده از دو مازول مجزا و هدفمند انجام شده است.

بخشی از کدهایی که از این مقاله که شامل معماری مدل اصلی بود در فایل پایتونی ام قرار دادم. قصد داشتم از این مدل یک inference انجام دهم تا با روش‌های کلاسیک مقایسه کنم؛ اما در نهایت تنها به بیان مطالعات، درک و برداشت خود از این نوع شبکه‌های عمیق بسنده کردم؛ زیرا یتاست‌های غنی و همچنین مدل‌ها و مقالات متعددی وجود دارند که بر روی همین زمینه فعالیت کرده‌اند و منبع خوبی برای یادگیری هستند.

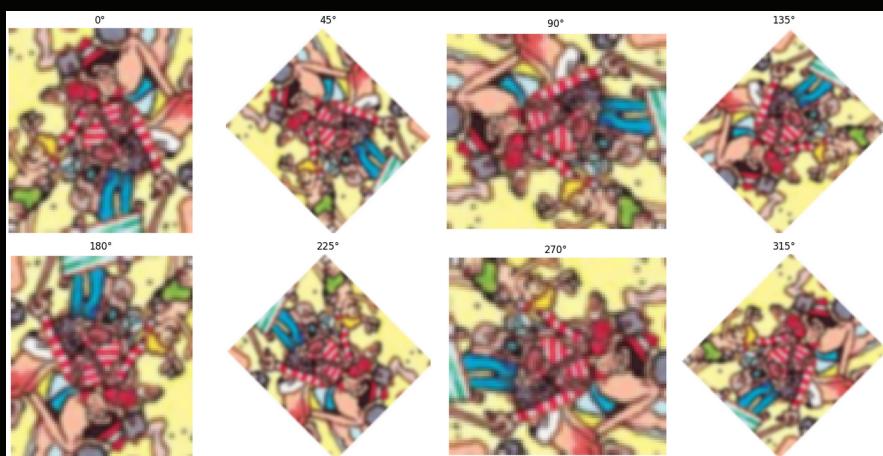
(۵) پروژه چهارم: والدو

برای این پروژه، سه شیوه اصلی پیاده شد:

۱. با استفاده از cross-correlation
۲. استفاده از هرم و پیاده سازی multi-resolution-correlation
۳. تهیه دیتاست و پیاده سازی با شبکه عصبی عمیق به تفصیل هر کدام از آنها در ادامه توضیح داده می شود:

پیاده سازی با کورولیشن

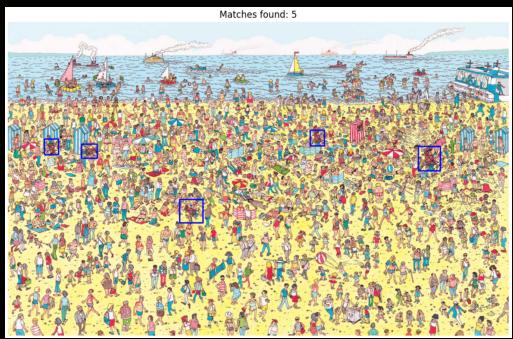
در این روش، در ابتدا کانفیگ های مختلف به ازای درجه های چرخیدن ۴۰، ۹۰، ۱۳۵، ۱۸۰، ۲۷۰، ۳۱۵، ۳۶۰ درجه و به ازای میزان اسیکلیک ۰.۸، ۰.۹، ۱.۰، ۱.۱، ۱.۲، ۱.۳، ۱.۴، ۱.۵ ساخته شد که در مجموع ۶۴ کانفیگ گوناگون را می سازند.



شکل ۱۴: جهت چرخش در تصویر ورودی والدو

سپس به کمک کتابخانه cv2 و با استفاده از تابع cross-correlation به ازای تصویر ورودی، انواع این ۶۴ کانفیگ به ورودی اعمال شد. در ابتدا، به ازای ورودی والدو و تصویر زمینه رنگی rgb ، تست گرفته شد که نتیجه خروجی مطلوب است و تمامی والدو ها به درستی تشخیص داده شده اند. (برای میزان شباهت باید بر روی متغیر ترشولد حداقل شباهت tuning میشد که پس از خروجی درست شد).

سپس برای همین متد ارائه شده، و با ورودی تصاویر زمینه و والدو grayscale شده نیز همین عملیات انجام شد و خروجی دقیقاً مشابه و البته با صرف یک سوم زمان به ازای ورودی رنگی انجام شد. و اما برای مقایسه زمان پیاده سازی: که به طرز واضحی نشان دهنده سرعت خروجی دادن یک سوم شده است و همان کیفیت نیز حفظ شده است.



شکل ۱۶: به ازای ورودی تصویر خاکستریس



شکل ۱۵: به ازای ورودی تصویر رنگی

زمان مصرف شده	نوع ورودی
15.819602489471436	به ازای ورودی خاکستری
5.439622163772583	به ازای ورودی رنگی

جدول ۶: زمان صرف شده برای پیدا کردن والدو

روش دوم برای کاهش زمان مصرف شده : multi-resolution

Multi-resolution correlation

- Multi-resolution template matching
 - reduce resolution of both template and image by creating an **image pyramid**
 - match small template against small image
 - identify locations of strong matches
 - expand the image and template, and match higher resolution template selectively to higher resolution image
 - iterate on higher and higher resolution images
- Issue:
 - how to choose detection thresholds at each level
 - too low will lead to too much cost
 - too high will miss match

شکل ۱۷: پیدا کردن والدو به کمک روش چند رزولوشنی طبق اسلاید های درسی

در این روش، به جای مقایسه الگوی کامل با تمام موقعیت‌های ممکن در تصویر اصلی با وضوح کامل، از هرم‌های تصویری استفاده می‌شود تا تطبیق به صورت تدریجی و از وضوح پایین به بالا انجام شود.

فرآیند با ساخت هرم‌هایی از تصویر ورودی و الگو آغاز می‌شود. هر سطح از هرم، نسخه‌ای کوچکتر (پایین‌نمونه‌گیری شده) از سطح قبلی است که عرض و ارتفاع آن به نصف کاهش می‌یابد. برای مثال، یک تصویر ۱۰۲۴×۱۰۲۴ در سطح ۱ به ۵۱۲×۵۱۲ و در سطح ۲ به ۲۵۶×۲۵۶ تبدیل می‌شود. تطبیق از پایین‌ترین سطح هرم (مثلًاً سطح ۲) آغاز می‌شود؛ جایی که تصویر کوچکتر است و پردازش سریع‌تر انجام می‌گیرد. در این سطح، یک جستجوی کامل انجام شده و ممکن است تعداد زیادی تطبیق تقریبی پیدا شود – مثلًاً حدود ۱۰۰۰ مورد.

این تطبیق‌های تقریبی در سطح بالاتر هرم (مثلاً سطح ۱) با دقت بیشتر بررسی و اصلاح می‌شوند. اما به جای بررسی کل تصویر، فقط نواحی اطراف تطبیق‌های قبلی بررسی می‌گردند. این کار به طور چشمگیری تعداد مقایسه‌ها را کاهش می‌دهد. بسیاری از تطبیق‌های ضعیف در این مرحله حذف می‌شوند و ممکن است تعداد کاندیدها از ۱۰۰۰ به ۲۰۰ مورد کاهش یابد.

در نهایت، در بالاترین سطح هرم (سطح ۰، یعنی تصویر با وضوح کامل)، تطبیق دقیق فقط در نواحی مربوط به آن ۲۰۰ کاندیدای فیلترشده انجام می‌شود، نه در کل تصویر. در این مرحله، تنها تطبیق‌های قوی و دقیق باقی می‌مانند.

این فرآیند پالایش سلسه‌مراتبی همان چیزی است که تطبیق مبتنی بر هرم را بسیار قدرتمند می‌سازد. در واقع، بار محاسباتی اصلی به سطوح پایین‌تر منتقل می‌شود که تطبیق در آن‌ها بسیار سریع‌تر است، و تنها برای نواحی مناسب در وضوح بالا وقت صرف می‌شود. نتیجه این است که سیستمی با دقت بالا ولی سرعت بسیار بیشتر نسبت به روش تطبیق کلی در وضوح کامل خواهیم داشت.

در نهایت، استفاده از این روش نیازمند tune کردن تعداد لایه‌ها نیز می‌باشد. نتیجه تیون کردن تعداد لایه‌ها به این شکل بود که هرچه لایه‌ها را بیشتر می‌کردم، تعداد مواردی که تشخیص داده می‌شد نیز بیشتر می‌شد و باید ترشولد را نیز بالاتر می‌بردم. این بالاتر بردن ترشولد باعث می‌شود والدوهایی که روتیت شده بودند (که به علت خاصیتی که از کیفیت والدو اصلی به دلیل روتیت شدن برخوردار نبودند) قابل تشخیص نباشند. بنابراین تعداد لایه‌ها را محدود به ۳ لایه کردم.

همچنین، طبق بررسی هایم، هر چقدر تعداد لایه‌ها بیشتر باشد، سرعت خروجی دادن نیز بیشتر می‌شد. (البته مسلماً این رابطه تا بینهایت لایه تاثیر گذار نیست، اما تا ۶ لایه تاثیر خودش را نشان میداد.) اما به این دلیل که کیفیت خروجی را کاهش میداد، در نهایت، به همان سه لایه بسنده کردم. همچنین از نظر سرعت نیز، به ازای ورودی ۶۴ کانفیگ توضیح داده شده، چنین است:

زمان مصرف شده	نوع ورودی
6.921	به ازای ورودی خاکستری
19.6	به ازای ورودی رنگی

جدول ۷: زمان صرف شده برای پیدا کردن والدو با هرم رزولوشن‌های مختلف

که البته نسبت به روش اولیه افزایش یافته است. دلیل آن هم می‌توان در این یافت که تعداد لایه‌ها محدود است و پیشرفت زمانی خودش را نمی‌تواند نشان دهد. همچنین این متدهای تیونینگ بود که توضیح داده شد.

یادگیری عمیق در پیدا کردن والدو

- Finding “Waldo” using a simple Convolutional Neural Network

با توجه به این صفحه مدیوم، در ابتدا یک دیتاست ساختم. دیتاست ساخته شده ام به این شکل عمل می‌کرد که در ابتدا یک سمت پل ۲۰۰*۲۰۰ از تصویر زمینه می‌گرفت و بعد با یک درصد رندومنس والدو را بر روی آن بر روی یک نقطه رندوم و با یک کانفیگ رندوم قرار میداد.

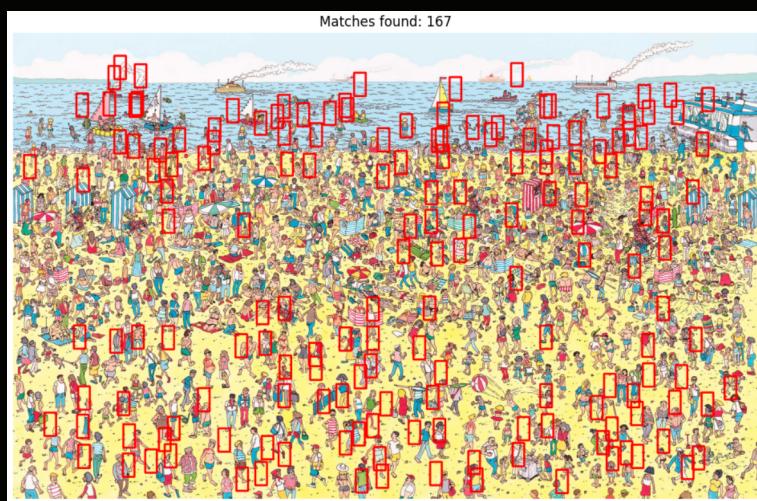
سپس بر روی یک شبکه عصبی pre-train شده از نوع mobile-net، هم classification به معنی بررسی حضور یا عدم حضور والدو و هم regression برای پیدا کردن موقعیت والدو پیاده سازی شد.

نتیجه این مدل این شد که حتی با کمترین ترشولد دقت نیز، تنها ۳۰ موقعیت تشخیص داده شده بود که همان هم خیلی رندوم بودند و اصلاً والدو نبودند.

سپس با بررسی بیشتر، دلیل این موضوع را به کم بودن دیتا والدو واقعی یافتم. بدین منظور دیتاست جدیدی ساختم که ۹۰ درصد دیتا والدو حاضر بود و در بقیه نبود و سپس فاین تیون کردن را انجام دادم. این مدل در پیدا کردن والدو، همانطور که انتظار میرفت، بیشتر ریسک میکرد، و تعداد بیشتری کاندید نشان میداد، اما باز هم والدو واقعی هیچی پیدا نکرد.

در نهایت دلیل اصلی عدم موفقیت این دو دیتاست و مدل ها را پیدا کردم: این که باید تصویر زمینه ثابت و برابر با کل تصویر اصلی باشد. باید ذکر کنم که انگیزه ام از شیوه قبلی تنظیم دیتاست، این بود که وقتی کل زمین را یکجا به مدل میدهیم، به نوعی یادگیری واقعی انجام نشده و به سمت ورودی بایاس می شویم. اما با خواندن مقاله، دیدم که ظاهرا همین نوع که کل تصویر زمینه اصلی را استفاده کنیم، روش استانداردی است. بدین منظور، دیتاست جدیدی ساختم که والدو ها را به شکل رندوم مشابه قبلی در تصویر patch میکرد، اما این تصویر، به جای سمپل های رندوم ۲۰۰۰*۲۰۰۰ از تصویر زمینه اصلی، کل تصویر زمینه اصلی بود.

نتیجه این دیتاست اخیری، این شد که گویا واقعاً یادگیری انجام میشد، شاخص loss از نزدیک به $k=1000$ رسید، که در همینجا متوقف شد. به دلیل سبک بودن بیش از حد مدل من، و همچنین کم بودن دیتا والدو (تنها ۵۰۰ تصویر ساختم که همگی شامل تصویر اصلی بودند). به علت محدودیت حافظه گوگل کولب (همان ۵۰۰ تصویر، نزدیک به ۷ گیگابایت رم از ۱۲ گیگ را اشغال کرده بوند)، مدل همچنان loss بالای داشت که عدد 1000 همچنان نمیتوانست جای والدو را به خوبی پیدا کند. در صورتی که میتوانستم از مدلی سنگین تر و همچنین دیتاستی غنی تر استفاده کنم، مسلماً به پاسخ بهتری میرسیدم، اما با همین مدل نهایی، یک والدو درست (و تعداد زیادی موارد نامرتب) تشخیص داده شد.



شکل ۱۸: والدو با شبکه عصبی سوم

همچنین شایان ذکر است مدت زمان inference این مدل سومی، حدود ۱۷ ثانیه طول میکشد که از روش های کلاسیک نیز بیشتر است.

در ابتدا، به کمک کتابخانه *cv2* تابع زیر را برای دریافت فیچرها تکمیل کردیم.

```
1 def extract_features(image_path)
2     # input is an image and the output is an array of features.
3
```

Listing 1: extract feature function



شکل ۲۱ : new caption

شکل ۲۰ : new caption

شکل ۱۹ : caption another

منابع

1. Image Denoising Algorithms: A Comparative Study of Different Filtration Approaches Used in Image Restoration. <https://ieeexplore.ieee.org/abstract/document/6524379/>
2. Digital Image Processing By Gonzalez 4th <https://elibrary.pearson.de/book/99.150005/9781292223070>
3. Automatic identification of noise in ice images using statistical features https://www.researchgate.net/figure/Simple-pattern-classifier-to-identify-noise-types-of-Gauss-tbl1_258714501
4. medium: A Beginners Guide to Computer Vision (Part 4)- Pyramid <https://medium.com/analytics-vidhya/a-beginners-guide-to-computer-vision-part-4-pyramid-3640edeffb00>
5. medium: A Beginners Guide to Computer Vision (Part 4)- Pyramid <https://medium.com/analytics-vidhya/a-beginners-guide-to-computer-vision-part-4-pyramid-3640edeffb00>
6. medium: A Beginners Guide to Computer Vision (Part 4)- Pyramid <https://medium.com/analytics-vidhya/a-beginners-guide-to-computer-vision-part-4-pyramid-3640edeffb00>
7. medium: A Beginners Guide to Computer Vision (Part 4)- Pyramid <https://medium.com/analytics-vidhya/a-beginners-guide-to-computer-vision-part-4-pyramid-3640edeffb00>